



# ПОСТАНОВКА ЗАДАЧИ



МИНОБРНАУКИ  
РОССИИ



МИРЭА —  
Российский  
технологический  
университет



РОСКОСМОС





# КРАТКОЕ СОДЕРЖАНИЕ ЗАДАЧИ

Участникам необходимо разработать веб-сервис для мониторинга вегетационной динамики сельскохозяйственных территорий. Пользователь выбирает регион и сельскохозяйственный полигон на карте либо задает собственный контур, после чего сервис самостоятельно получает доступные спутниковые и метеорологические данные, формирует временной ряд NDVI, восстанавливает пропуски и выявляет периоды аномального развития растительности. Результаты анализа должны отображаться в понятной визуальной форме на карте и графиках. Итоговое решение должно быть воспроизводимым и позволять пройти основной пользовательский сценарий без предварительной ручной подготовки и загрузки данных.

## ПОЛНОЕ ОПИСАНИЕ ЗАДАЧИ

Командам предстоит построить решение, которое превращает нерегулярные и частично пропущенные спутниковые наблюдения в непрерывный, интерпретируемый ряд состояния растительности и помогает находить нетипичные периоды развития посевов.

В рамках кейса решаются две связанные задачи:

**Задача 1. Интерполяция временного ряда.** Для намеренно скрытых контрольных точек необходимо восстановить значение `primary_ndvi`. Эта задача оценивается автоматически на платформе.

**Задача 2. Детекция и интерпретация аномалий.** Решение должно находить периоды угнетения/нетипичного поведения растительности и, по возможности, объяснять их с опорой на временной ряд, климатическую норму, погодные признаки и данные нескольких источников.

Веб-интерфейс является обязательной частью решения и должен позволять выбрать территорию, просмотреть исходный и восстановленный временной ряд, увидеть выявленные аномалии и их интерпретацию.



## ПРОБЛЕМАТИКА

Спутниковые временные ряды сельскохозяйственных полей редко бывают готовыми к непосредственному анализу. Облачность, тени, различная периодичность съемки Sentinel-2, Landsat и MODIS, ошибки маскирования и отсутствие пригодной сцены на конкретную дату приводят к пропускам и локальным выбросам. Из-за этого простой график индекса растительности может давать ложное представление о развитии посевов.

Одновременно агроному или аналитику важен не сам факт изменения NDVI, а ответ на вопрос, является ли изменение нормальной фазой сезонного цикла или признаком угнетения, засухи либо другой аномалии. Для этого нужно сравнивать текущую динамику с исторической нормой и учитывать погодный контекст.

# КОНЦЕПЦИЯ РЕШЕНИЯ


Итогом должен стать полноценный веб-сервис для мониторинга вегетационной динамики сельскохозяйственных территорий. Пользователь указывает интересующий регион в интерфейсе, после чего сервис сам находит доступные сельскохозяйственные контуры и собирает необходимые данные для анализа.

Сервис должен поддерживать два базовых сценария работы с территорией:

- ✦ выбор готового сельскохозяйственного полигона на карте из доступных открытых источников, например OpenStreetMap / ESA WorldCereal;
- ✦ самостоятельное выделение пользователем произвольного полигона на карте.

После выбора полигона сервис автоматически получает доступные спутниковые и метеорологические данные из открытых источников и API, формирует временной ряд вегетационных индексов, выполняет его очистку и восстановление, выявляет негативные аномальные периоды и отображает результат на карте и графиках. Основной пользовательский сценарий не должен требовать ручной загрузки заранее подготовленного датасета.

(Для автоматической проверки задачи 1 решение должно формировать submission.csv с восстановленными значениями primary\_ndvi для контрольных пропусков.)






## ПРОДУКТОВАЯ ЦЕЛЬ

Сервис должен позволять быстро оценить состояние выбранной территории: увидеть динамику **primary\_ndvi**, отличить исходные наблюдения от восстановленных значений, определить периоды негативного отклонения от нормы и получить понятную интерпретацию выявленных аномалий. Результаты должны быть представлены в удобной визуальной форме на карте и графиках.

В качестве дополнительных возможностей команды могут реализовать сохранение и управление набором полигонов, расширенные механизмы поиска сельскохозяйственных контуров, дополнительную аналитику и более детальное объяснение возможных причин обнаруженных аномалий.





# **ТЕОРЕТИЧЕСКИЙ РАЗДЕЛ И ГЛОССАРИЙ**

Ниже приведен минимальный набор понятий и подходов, необходимый для понимания постановки. Он не задает обязательную архитектуру решения: участники могут применять статистические методы, классические алгоритмы обработки временных рядов, ML/DL или их комбинации.

## ГЛОССАРИЙ

**AOI / полигон поля** - область интереса (Area of Interest), соответствующая контуру сельскохозяйственного участка. В тестовых данных полигоны обозначаются анонимными идентификаторами `anon_polygon_id`.

**NDVI** - Normalized Difference Vegetation Index, базовый индекс вегетации растительности.

**EVI** - Enhanced Vegetation Index, дополнительный индекс растительности, менее чувствительный к части атмосферных эффектов и насыщению NDVI.

**NDWI** - индекс, используемый для оценки водного сигнала/влажностных особенностей в зависимости от выбранной спектральной формулы.

**primary\_ndvi** - основной согласованный ряд NDVI, относительно которого ставится задача восстановления пропусков.

**Gap / пропуск** - дата/наблюдение, для которого целевое значение временного ряда отсутствует.

**Climatology / климатическая норма** - ожидаемое значение индекса для данного периода сезона, рассчитанное по историческим наблюдениям.

**Z-score** - стандартизованное отклонение текущего значения от исторической нормы:  $z = (x - \text{mean}) / \text{std}$ .

**Аномалия** - нетипичное относительно нормы состояние временного ряда, например устойчивое снижение вегетационного индекса, потенциально связанное с засухой или угнетением посевов.

**RMSE** - корень из средней квадратичной ошибки; сильнее штрафует крупные промахи восстановления.

# ТЕОРЕТИЧЕСКАЯ БАЗА

**1. Восстановление временных рядов (задача 1).** Из-за нерегулярной спутниковой съемки и облачности значения NDVI наблюдаются не каждый день. Простейший baseline для одиночного пропуска - взять ближайшее известное значение до него и ближайшее после него и усреднить. Более развитые подходы могут учитывать расстояние по времени, сезонную форму кривой и несколько сенсоров: линейная/сплайн-интерполяция, Savitzky-Golay, Whittaker smoother, модели временных рядов и ML.



Рисунок - визуализация концепции интерполяции данных

**2. Минимальный подход к поиску аномалий (задача 2).** Один из простейших способов - сравнить наблюдаемое значение с исторической нормой для той же фазы сезона это использовать формулу:

$$Z = \frac{NDVI_{fact} - NDVI_{climatology_{mean}}}{NDVI_{climatology_{std}}}$$

Z-score показывает, на сколько стандартных отклонений текущее значение NDVI отличается от климатической нормы для этого полигона и примерно этого момента сезона. Устойчивые и/или сильные отрицательные отклонения являются кандидатами на угнетение растительности. Стандартная интерпретация Z-score:

### Диапазон значений

### Аномалия

$$Z \geq -1$$

Штатное развитие

$$-2 \leq Z < -1$$

Угнетение биомассы

$$Z < -2$$

Критическая аномалия




Рисунок - визуализация предлагаемых аномалий

Участники могут детектировать другие аномалии или применять другой подход, но нужно будет аргументировать выбор

**3. Контекст аномалии.** Отрицательное отклонение NDVI само по себе не объясняет причину. Для более сильного решения полезно сопоставлять сигнал с температурой и осадками ERA5/ERA5-Land, другими индексами и соседними датами, отделяя погодный стресс от выбросов, облаков, смены сельскохозяйственной фазы и ошибок данных.

**4. Обобщающая способность.** Решение должно сохранять качество при переносе на новые полигоны и регионы. Поэтому рекомендуется строить валидацию так, чтобы часть полей или сезонов полностью оставалась вне обучения.

**5. Самостоятельный сбор обучающих данных.** Основной канал - Google Earth Engine или прямые открытые источники. Рекомендуемые коллекции: Sentinel-2 SR (COPERNICUS/S2\_SR\_HARMONIZED), Landsat 8/9 Level-2, MODIS NDVI/EVI (MODIS/061/MOD13Q1), ERA5-Land (ECMWF/ERA5\_LAND/HOURLY), ESA WorldCover, ESA WorldCereal и OpenStreetMap/Overpass API для контуров полей.





# ДАННЫЕ СОРЕВНОВАНИЯ

Участникам с начала хакатона предоставляются два набора данных: обучающий `train_dataset.csv` и тестовый `private_features.csv`. Данные представлены в табличном виде: одна строка соответствует одному анонимизированному полигону в одну дату. Строка однозначно идентифицируется комбинацией `anon_polygon_id + date`.

В данных используются `anon_polygon_id`, `date`, спутниковые индексы Sentinel-2, Landsat и MODIS, метеоданные ERA5, календарные признаки `year` и `day-of-year`, `primary_ndvi`, характеристики климатической нормы, `n_reference_years`, служебный признак `is_synthetic_gap` и статичный `crop_type`.

В `train_dataset.csv` целевые значения `primary_ndvi` известны. В `private_features.csv` для контрольных строк с `is_synthetic_gap = True` значение `primary_ndvi` скрывается, а динамические и вычисляемые признаки этой строки маскируются.



## TRAIN (ОБУЧАЮЩИЙ ДАТАСЕТ)

Участникам предоставляется reference-набор `train_dataset.csv` на 99 955 строк с известным `primary_ndvi` и сопутствующими признаками, кроме этого в `train` датасете есть `ndvi_zscore` и `status`, которых не будет в `test`. Его можно использовать для построения `baseline`, обучения и проверки пайплайна. При необходимости команды могут расширять обучающую выборку за счет открытых источников.



Для использования и самостоятельного расширения train рекомендуется:

- ✧ использовать доступные контуры сельскохозяйственных полей из OpenStreetMap/Overpass API, ESA WorldCereal либо собственные полигоны;
- ✧ собирать дополнительные временные ряды Sentinel-2, Landsat и MODIS по выбранным полигонам;
- ✧ добавлять погодные признаки ERA5/ERA5-Land или данные других открытых метеоисточников;
- ✧ самостоятельно создавать валидационные synthetic gaps из известных точек, чтобы сравнивать методы восстановления;
- ✧ фиксировать источники данных, параметры фильтрации облаков, агрегации и все этапы предобработки для воспроизводимости.

Допускается использование других открытых источников и публичных предобученных моделей, если это не нарушает их лицензии и правила соревнования. Все внешние данные и модели должны быть перечислены и описаны в отчете и README.

## TEST (ТЕСТОВЫЙ DATASET)

Участникам с начала хакатона предоставляется тестовый dataset `private_features.csv`. Для контрольных точек значение `primary_ndvi` скрывается, строка помечается `is_synthetic_gap = True`, а остальные динамические и вычисляемые признаки в этой строке также маскируются. Участник должен восстановить `primary_ndvi` только для строк с `is_synthetic_gap = True`.

Правильные значения `primary_ndvi` для контрольных точек участникам не предоставляются. Ground truth хранится у организаторов и используется только для автоматической оценки решений на платформе.



Для проверки задачи 1 команда формирует submission.csv с предсказанными значениями primary\_ndvi для всех контрольных точек и загружает его на платформу. После загрузки submission платформа автоматически сопоставляет предсказания со скрытыми правильными ответами и рассчитывает итоговые RMSE и GapScore.

Естественные пропуски, возникшие из-за отсутствия пригодного спутникового наблюдения, сами по себе не являются контрольными точками автоматической метрики. Для задачи 1 оцениваются только строки, специально помеченные is\_synthetic\_gap = True.

## ФОРМАТ SUBMISSION.CSV

Для автоматической оценки задачи 1 команда формирует submission.csv только для строк, где is\_synthetic\_gap = True. Файл должен содержать:

- ✧ anon\_polygon\_id - анонимный идентификатор полигона;
- ✧ date - дата контрольной точки в формате YYYY-MM-DD;
- ✧ primary\_ndvi\_pred - восстановленное значение primary\_ndvi (вещественное число).

Пара anon\_polygon\_id + date должна встречаться в submission ровно один раз и соответствовать контрольной строке тестового набора. Пропуски, NaN и дополнительные строки не допускаются. Разделитель CSV - запятая, кодировка - UTF-8.

### Пример:

```
anon_polygon_id,date,primary_ndvi_pred
AOI-0001,2025-06-14,0.543218
AOI-0037,2025-07-03,0.391005
```



# МЕТРИКА ОЦЕНКИ

Автоматическая метрика применяется только к задаче 1 - восстановлению primary\_ndvi. По всем контрольным точкам тестового набора рассчитывается RMSE между истинным primary\_ndvi\_true и предсказанием команды:

$$\text{RMSE} = \sqrt{(1 / N) * \sum((y\_true - y\_pred)^2)}$$

RMSE переводится в нормированный GapScore от 0 до 30 относительно фиксированного порога 0.10. Порог соответствует примерно качеству простого baseline, который восстанавливает пропуск средним двух ближайших известных значений. Решение с RMSE = 0 получает GapScore = 30, а решение с RMSE >= 0.10 - GapScore = 0.

$$\text{GapScore} = \text{round}(30 * \max(0, 1 - \text{RMSE\_team} / 0.10), 2)$$

Таблица - примеры преобразования RMSE в GapScore

| RMSE команды | GapScore |
|--------------|----------|
| 0.10 и выше  | 0        |
| 0.08         | 6        |
| 0.05         | 15       |
| 0.02         | 24       |
| 0.00         | 30       |



# ТЕХНИЧЕСКИЕ ТРЕБОВАНИЯ И ВОСПРОИЗВОДИМОСТЬ


Эксперты должны иметь возможность воспроизвести финальный результат по предоставленному репозиторию и инструкции без ручного исправления исходного кода

## ЗАПУСК РЕШЕНИЯ / ИНФЕРЕНС

Решение должно иметь две воспроизводимые точки запуска: веб-сервис, где пользователь указывает регион и выбирает или рисует полигон, после чего данные собираются и анализируются автоматически; и технический batch-инференс, который принимает `private_features.csv` и формирует `submission.csv` для строк `is_synthetic_gap = True`.

В веб-интерфейсе эксперт должен видеть выбранный полигон, исходный и восстановленный ряд `primary_ndvi`, а также найденные негативные аномальные периоды и их интерпретацию. Отдельный `submission` по статусам аномалий не требуется.

Допускается любой стек. В README должны быть указаны команды запуска веб-сервиса и batch-инференса, зависимости, настройки внешних API и ожидаемые входные/выходные файлы.






# ВОСПРОИЗВОДИМОСТЬ

Воспроизводимость охватывает reference train, обучение/настройку алгоритмов, технический инференс и автоматический сбор данных веб-сервисом. Необходимо зафиксировать:

- ✧ внешние датасеты, геопорталы, API и идентификаторы используемых коллекций;
- ✧ логику поиска региона, выбора готовых контуров и задания произвольного полигона;
- ✧ маскирование облаков, агрегацию по полигону, расчет индексов и формирование временного ряда;
- ✧ команды обучения и инференса, random seed и ключевые гиперпараметры;
- ✧ версии зависимостей, подготовку окружения и настройки доступа к внешним API;
- ✧ порядок запуска веб-сервиса и получения submission.csv в техническом режиме.

Предпочтительно предоставить Dockerfile/docker-compose или другой способ фиксации окружения; иначе README должен содержать однозначную инструкцию установки и запуска всех обязательных компонентов.





# СОСТАВ ИТОГОВОГО РЕШЕНИЯ

Для финальной технической проверки и экспертной оценки команда должна предоставить полный комплект материалов, позволяющий воспроизвести результат и понять проведенное исследование.

## РЕПОЗИТОРИЙ

Репозиторий должен содержать полный исходный код решения: подготовку/загрузку данных (в той части, где это возможно), предобработку, обучение, инференс, модуль детекции аномалий, конфигурации.

Структура проекта должна быть понятной: точки входа, конфигурации и основные модули не должны требовать поиска по разрозненным файлам или ручного переноса кода.

## README.MD

README должен позволять эксперту запустить решение без обращения к команде. Минимально необходимо описать:

- ✧ назначение решения и структуру репозитория;
- ✧ подготовку окружения и установку зависимостей;
- ✧ источники и структуру данных;
- ✧ команды/скрипты сбора и предобработки данных, если они предоставляются;
- ✧ команду обучения или порядок подключения готовых артефактов;
- ✧ команду инференса и место появления submission.csv;
- ✧ способ запуска детекции аномалий и демонстрационного интерфейса.

## ОКРУЖЕНИЕ И ЗАВИСИМОСТИ

Команда должна зафиксировать версии зависимостей одним из стандартных способов: requirements.txt, pyproject.toml/lock-файл, environment.yml, Dockerfile или аналогичным механизмом для выбранного стека. Все внешние системные зависимости также должны быть перечислены.



# МОДЕЛЬ, ВЕСА И ДРУГИЕ АРТЕФАКТЫ

Если решение использует обученные модели, веса, скейлеры, сохраненные статистики климатологии, индексы, конфигурации или другие артефакты, они должны быть доступны организаторам и подключаться по инструкции без ручных доработок. Допускается хранение больших файлов по внешней ссылке, указанной в README.

## ИССЛЕДОВАТЕЛЬСКИЙ ОТЧЕТ

Помимо кода команда предоставляет исследовательский отчет в свободной форме. Его задача - показать ход работы, обоснованность принятых решений и возможность воспроизвести результат. Рекомендуется отразить:

- краткое описание задачи и протокола оценки;

- EDA: структура временных рядов, пропуски, сезонность, выбросы, различия между полигонами/регионами и другие значимые наблюдения;

- какие исходные и дополнительные данные использовались, откуда они были получены и почему были выбраны;

- baseline/отправную точку и ее ограничения;

- проверенные гипотезы, эксперименты и сравнение вариантов решения;

- какие изменения дали или не дали прирост качества интерполяции;

- логику детекции аномалий, примеры найденных случаев и способ их интерпретации;

- обоснование финальной конфигурации решения;

- ограничения подхода, проблемные случаи и возможные направления дальнейшего развития;

- инструкции и параметры, необходимые для воспроизводимости обучения и инференса.

Простая демонстрация графиков без выводов не считается полноценным анализом: важно показывать связку наблюдения, решения/гипотезы, эксперимента, вывода.



# ПРЕЗЕНТАЦИЯ

Финальная презентация должна кратко показать проблематику, данные, выбранный подход и работающий результат. Рекомендуется включить: baseline и улучшение относительно него, итоговый GapScore/RMSE, логику детекции аномалий, 2-3 показательных временных ряда, архитектуру/пайплайн, демонстрацию интерфейса и выводы по ограничениям и развитию решения.

Во время защиты команда должна быть готова объяснить происхождение обучающих данных, причины выбора методов, результаты ключевых экспериментов и то, как решение ведет себя на новых полигонах/регионах.

